

Lecture 4


Clustering

AIE324 — Unsupervised Machine Learning

Dr. Suparat Yeamkuan

ดร. ศุภรัตน์ แยมครวญ

suparat.y@bu.ac.th



School of Engineering
Artificial Intelligence Engineering and Data Science

Outline

- What's a Clustering? and Applications
- Data Clustering
- Clustering Models/Algorithms
 - Partitional – Based
 - Hierarchical – Based*
 - Density – Based*
- Q&A

What is Clustering?

การแบ่งกลุ่มข้อมูล (Clustering)

คือกระบวนการจัดกลุ่มของตัวอย่างข้อมูล (Observations) หรือ รูปแบบ (Patterns) เข้าด้วยกันตาม ความคล้ายคลึงกัน (Similarity)


Core Concept → ความคล้ายคลึงและแตกต่าง

ข้อมูลที่ถูกจัดอยู่ในกลุ่มเดียวกัน (Cluster) จะมีความคล้ายคลึงกันมากที่สุด ในขณะที่ข้อมูลที่อยู่ต่างกลุ่มกันจะมีความแตกต่างกันมากที่สุด




Clustering Applications

- Business and Marketing
 - Market/Customer Segmentation
 - Recommender Systems
- Image Processing and Computer Vision
- Natural Language Processing (NLP)
 - Document Retrieval
 - Topic Modeling
- Data Management and Modeling




Clustering Applications: Customer Clustering



<https://hex.tech/templates/data-clustering/customer-segmentation/>


Clustering Applications: Image Clustering



<https://voxel51.com/blog/how-to-cluster-images>



Clustering Applications: Text Clustering




<https://carrotsearch.com/>

Image Source: https://www.youtube.com/watch?v=6Kx_YunOOBM



Clustering Models/Algorithms

Clustering in Machine Learning



Partitional – Based Clustering



Partitional – Based Clustering

Partition-Based Clustering การจัดกลุ่มข้อมูลแบบแบ่งส่วน

เป็นวิธีการจัดกลุ่มข้อมูล ที่แบ่งข้อมูลออกเป็นหลายกลุ่ม โดยกำหนดจำนวนกลุ่มล่วงหน้า และพยายามจัดข้อมูลที่มีลักษณะคล้ายกันให้อยู่ในกลุ่มเดียวกัน

หลักการสำคัญ: การใช้การวัดระยะห่างหรือความคล้ายคลึงของข้อมูล เช่น Euclidean Distance เพื่อให้ข้อมูลภายในกลุ่มมีความใกล้เคียงกันมากที่สุด และข้อมูลระหว่างกลุ่มมีความแตกต่างกันมากที่สุด

นิยมใช้ในงานแบ่งกลุ่มลูกค้า การวิเคราะห์พฤติกรรมผู้ใช้ และการวิเคราะห์ข้อมูลเชิงวิศวกรรม


อัลกอริทึม (Centroid-Based Clustering)

- K-Means
- Fuzzy C-Means

พื้นฐานที่จำเป็น

- Metrics ทางสถิติ (Statistical Metrics)
- การวัดระยะห่างของข้อมูล (Distance Measurement)
- การกระจายของข้อมูล (Data Spread)
- การปรับขนาดข้อมูล (Data Scaling)

Partitional – Based Clustering



Centroid-based clustering

การจัดกลุ่มแบบใช้เซนทรอยด์ (Centroid)

- การใช้ค่าเฉลี่ยเลขคณิตของจุดข้อมูลทั้งหมดในกลุ่มมาเป็นตัวแทนของกลุ่มนั้น
- การจัดกลุ่มแบบนี้จะจัดข้อมูลออกเป็นกลุ่มแบบไม่เป็นลำดับชั้น (non-hierarchical clusters)

อัลกอริทึมประเภทนี้มีประสิทธิภาพสูง แต่มีความไวต่อค่าเริ่มต้น (initial conditions) และค่าผิดปกติ (outliers)

Example of centroid-based clustering.

<https://developers.google.com/machine-learning/clustering/clustering-algorithms>

Partitional – Based Clustering

From Dataset → Clustering → Labels

	Feature_1	Feature_2
0	1.190043	0.848595
1	-3.436033	8.082827
2	0.649228	10.549156
3	2.614217	2.601664
4	-2.977504	8.546012
5	2.823831	-0.851438
6	4.774935	-0.876327
7	-2.025273	5.187726
8	-3.448146	10.099406
9	7.571176	1.521617

Dataset

Centroid-Based Clustering

- K-Means
- Fuzzy C-Means

Algorithm Result

- Centroids
- Cluster

	Feature_1	Feature_2	Cluster
0	1.190043	0.848595	1
1	-3.436033	8.082827	2
2	0.649228	10.549156	2
3	2.614217	2.601664	1
4	-2.977504	8.546012	2
5	2.823831	-0.851438	1
6	4.774935	-0.876327	1
7	-2.025273	5.187726	2
8	-3.448146	10.099406	2
9	7.571176	1.521617	1


K-Means Clustering

K-Means เป็นเทคนิคการจัดกลุ่มแบบ Centroid-based หรืออ้างอิงจุดศูนย์กลาง โดยมีเป้าหมายหลักคือ **ลดค่าความแปรปรวนภายในกลุ่ม** (Within-cluster variation) หรือที่เรียกว่า **Inertia** หรือผลรวมของระยะทาง (Distance) กำลังสองระหว่างจุดข้อมูลกับจุดศูนย์กลางของกลุ่มที่สังกัดอยู่ให้เหลือน้อยที่สุด


ขั้นตอนของอัลกอริทึม

กระบวนการทำงานเป็นแบบทำซ้ำ (Iterative) ซึ่งประกอบด้วยขั้นตอนหลักดังนี้

1. กำหนดค่า k ระบุจำนวนกลุ่มที่ต้องการแบ่ง
2. Initialization: การกำหนดจุดเริ่มต้น
3. Assignment Step: วัดระยะห่างระหว่างข้อมูลแต่ละจุดกับ Centroids
4. Update Step: คำนวณหาตำแหน่งใหม่ของ Centroid สำหรับแต่ละกลุ่ม
5. Convergence: การทำซ้ำขั้นตอนที่ 3 และ 4 ซ้ำไปเรื่อยๆ




K-Means Clustering



Elbow: Optimal Cluster Number

Elbow Method: Optimal Cluster Number คือเทคนิคที่ใช้ในการหาจำนวนกลุ่ม (K) ที่เหมาะสมที่สุดในการทำ Clustering เช่น K-Means



หลักการทำงาน

- Elbow Method จะทดลองแบ่งกลุ่มด้วยค่า K หลายค่า แล้วคำนวณค่า Within-Cluster Sum of Squares (WCSS) หรือความกระจายตัวภายในกลุ่ม จากนั้นพล็อตกราฟระหว่างค่า K กับ WCSS

จุดที่กราฟเริ่มโค้งเหมือน “ข้อศอก (Elbow)” คือจำนวน Cluster ที่เหมาะสม เพราะหลังจากจุดนั้น การเพิ่มจำนวน Cluster จะช่วยลดความผิดพลาดได้น้อยลง

K-Means Clustering

ตัวอย่างการคำนวณ K-Means Clustering

โจทย์การคำนวณ K-means Clustering

กำหนดชุดข้อมูล 2 มิติ จำนวน 6 จุด ดังนี้

$$A(1, 1), \quad B(1.5, 2), \quad C(3, 4), \quad D(5, 7), \quad E(3.5, 5), \quad F(4.5, 5)$$

กำหนดจำนวนกลุ่ม $k = 2$ กำหนดสูตรการคำนวณระยะทางแบบ Euclidean

K-Means Clustering


Step 1: กำหนด Centroid เริ่มต้น

เลือก Centroid เริ่มต้นแบบสุ่ม โดยใช้จุด A เป็นเซนทรอยด์กลุ่มที่ 1 C_1 และใช้จุด D เป็นเซนทรอยด์กลุ่มที่ 1 C_2

กำหนด $k = 2$ เริ่มต้น 2 Centroids

$$C_1 = (1, 1)$$


$$C_2 = (5, 7)$$



รูปที่ 1: การกำหนด Centroid เริ่มต้น

K-Means Clustering

Step 2: คำนวณระยะ Euclidean



รูปที่ 2: ระยะ Euclidean จาก เซนทรอยด์ C_1 และ C_2 ไปยังแต่ละจุด

K-Means Clustering

คำนวณระยะของแต่ละจุด

Point A(1,1)

ทำการคำนวณระยะห่างระหว่างจุด A ไปยังเซนทรอยด์ C_1 และ C_2 โดยใช้ระยะทางแบบ Euclidean ดังนี้

$$d(A, C_1) = \sqrt{(1-1)^2 + (1-1)^2} = 0$$

ค่า Min เกิดที่ C_1

$$d(A, C_2) = \sqrt{(1-5)^2 + (1-7)^2} = \sqrt{16+36} = \sqrt{52} = 7.21$$

ทำการหาค่าต่ำสุดจากการคำนวณระยะทางระหว่าง $d(A, C_1)$ และ $d(A, C_2)$

$$\arg \min_{k \in \{1,2\}} d(x, C_k) = \min\{d(A, C_1), d(A, C_2)\} = \min\{0, 7.21\} = 0$$

$x \in \text{Cluster 1}$

ค่าต่ำสุดเท่ากับ 0 ซึ่งเป็นค่าที่เกิดจาก $d(A, C_1)$ ดังนั้นจุด A ถูกกำหนดให้อยู่ใน Cluster 1

Point A $\rightarrow$ Cluster 1

K-Means Clustering

Point B(1.5,2)

$$d(B, C_1) = \sqrt{(1.5 - 1)^2 + (2 - 1)^2} = \sqrt{0.25 + 1} = 1.12$$

$$d(B, C_2) = \sqrt{(1.5 - 5)^2 + (2 - 7)^2} = \sqrt{12.25 + 25} = 6.10$$

Point B → Cluster 1

Point C(3,4)

$$d(C, C_1) = \sqrt{(3 - 1)^2 + (4 - 1)^2} = \sqrt{4 + 9} = 3.61$$

$$d(C, C_2) = \sqrt{(3 - 5)^2 + (4 - 7)^2} = \sqrt{4 + 9} = 3.61$$

Point C → Cluster 1

K-Means Clustering

Point D(5,7)

$$d(D, C_1) = \sqrt{(5-1)^2 + (7-1)^2} = 7.21$$

$$d(D, C_2) = 0$$

Point D → Cluster 2

Point E(3.5,5)

$$d(E, C_1) = \sqrt{(3.5-1)^2 + (5-1)^2} = \sqrt{6.25 + 16} = 4.72$$

$$d(E, C_2) = \sqrt{(3.5-5)^2 + (5-7)^2} = \sqrt{2.25 + 4} = 2.50$$

Point E → Cluster 2

Point F(4.5,5)

$$d(F, C_1) = \sqrt{(4.5-1)^2 + (5-1)^2} = \sqrt{12.25 + 16} = 5.31$$

$$d(F, C_2) = \sqrt{(4.5-5)^2 + (5-7)^2} = \sqrt{0.25 + 4} = 2.06$$

Point F → Cluster 2

K-Means Clustering

Step 3: ผลการจัดกลุ่มรอบที่ 1

Cluster 1:

A, B, C

Cluster 2:

D, E, F

Step 4: คำนวณ Centroid ใหม่

Cluster 1:

$A(1, 1), B(1.5, 2), C(3, 4)$

$$C_1^{new} = \left(\frac{1 + 1.5 + 3}{3}, \frac{1 + 2 + 4}{3} \right)$$


$$C_1^{new} = (1.83, 2.33)$$

Cluster 2:


$D(5, 7), E(3.5, 5), F(4.5, 5)$

$$C_2^{new} = \left(\frac{5 + 3.5 + 4.5}{3}, \frac{7 + 5 + 5}{3} \right)$$

$$C_2^{new} = (4.33, 5.67)$$



K-Means Clustering



รูปที่ 3: เปรียบเทียบระหว่าง Centroid เริ่มต้นกับ Centroid คำนวณใหม่

ผลลัพธ์การจัดกลุ่ม


Cluster	Points	Centroid
Cluster 1	$\{A, B, C\}$	(1.83, 2.33)
Cluster 2	$\{D, E, F\}$	(4.33, 5.67)

Fuzzy C-Means Clustering


Fuzzy C-Means Clustering (FCM) คืออัลกอริทึมการจัดกลุ่มข้อมูลแบบ **Soft Clustering** ที่อนุญาตให้ข้อมูล 1 จุดสามารถเป็นสมาชิกของได้หลายกลุ่ม โดยกำหนดค่า ระดับความเป็นสมาชิก (Membership Degree) ให้กับแต่ละกลุ่ม

หลักการทำงาน

- FCM จะกำหนดค่า Membership ของจุดข้อมูล ต่อทุก Cluster
- คำนวณตำแหน่ง Centroid โดยใช้ค่าน้ำหนักจาก Membership แล้วปรับค่า Membership
- คำนวณตำแหน่ง Centroid ซ้ำไปเรื่อย ๆ จนกว่าจะได้ผลลัพธ์ที่เหมาะสม ทำให้สามารถจัดการข้อมูลที่มีขอบเขตกลุ่มไม่ชัดเจนได้ดี




Fuzzy C-Means Clustering



K-Mean vs Fuzzy C-Means Clustering


K-Means = Hard Clustering

- ข้อมูล 1 จุด อยู่ได้แค่ 1 กลุ่มเท่านั้น




Fuzzy C-Means = Soft Clustering

- ข้อมูล 1 จุด สามารถอยู่หลายกลุ่มได้
- มีค่า membership ว่าอยู่แต่ละกลุ่มมากน้อยแค่ไหน



Hierarchical – Based Clustering



Hierarchical – Based Clustering

Hierarchical-Based Clustering การจัดกลุ่มข้อมูลแบบลำดับชั้น


เป็นวิธีการจัดกลุ่มข้อมูล ที่สร้างโครงสร้างกลุ่มข้อมูลแบบลำดับชั้น โดยแสดงความสัมพันธ์ของข้อมูลในรูปแบบแผนผังต้นไม้ (Dendrogram) และไม่จำเป็นต้องกำหนดจำนวนกลุ่มล่วงหน้า

หลักการสำคัญ

การรวมกลุ่มข้อมูลที่มีความคล้ายคลึงกัน หรือแยกกลุ่มข้อมูลที่แตกต่างกันออกเป็นลำดับชั้น โดยสามารถแบ่งได้เป็น 2 วิธี

- การรวมกลุ่มย่อยไปกลุ่มใหญ่ (Agglomerative Clustering)
- การแยกกลุ่มจากใหญ่ลงมากกลุ่มเล็ก (Divisive Clustering)


**งานส่วนมากใช้ Agglomerative Clustering*



รูปแบบแผนผังต้นไม้ (Dendrogram)

<https://support.minitab.com>

Types of Hierarchical Clustering



Agglomerative Clustering


Agglomerative Clustering คืออัลกอริทึมการจัดกลุ่มข้อมูลแบบ Hierarchical Clustering (แบบล่างขึ้นบน – Bottom-Up) โดยเริ่มจากให้ข้อมูลแต่ละจุดเป็นกลุ่มของตัวเอง แล้วค่อย ๆ รวมกลุ่มที่อยู่ใกล้กันเข้าด้วยกัน จนได้จำนวนกลุ่มตามต้องการ

หลักการทำงาน

- เริ่มต้นให้ทุกจุดข้อมูลเป็น 1 Cluster
- คำนวณระยะห่างระหว่าง Cluster
- รวม Cluster ที่อยู่ใกล้กันที่สุด
- ทำซ้ำจนได้จำนวน Cluster ที่กำหนด หรือรวมเป็นกลุ่มเดียว

การวัดระยะระหว่างกลุ่มนิยมใช้ เช่น

- Single Linkage (ใช้ระยะจุดที่ใกล้ที่สุด)
- Complete Linkage (ใช้ระยะจุดที่ไกลที่สุด)
- Average Linkage (ใช้ค่าเฉลี่ยระยะทาง)
- Ward Method (ลดความแปรปรวนในกลุ่ม)




Divisive Clustering

Divisive Clustering คืออัลกอริทึมการจัดกลุ่มข้อมูลแบบ Hierarchical Clustering (แบบบนลงล่าง – Top-Down) โดยเริ่มจากนำข้อมูลทั้งหมดรวมเป็นกลุ่มเดียวก่อน แล้วค่อย ๆ แบ่งกลุ่มออกเป็นกลุ่มย่อย จนได้จำนวนกลุ่มที่ต้องการ

หลักการทำงาน


- เริ่มต้นจากข้อมูลทั้งหมดเป็น 1 Cluster
- เลือก Cluster ที่มีความแตกต่างภายในสูง
- แบ่ง Cluster นั้นออกเป็นกลุ่มย่อย เช่น K-Means
- ทำซ้ำจนได้จำนวน Cluster ที่ต้องการ



Dendrogram

Dendrogram คือแผนภาพแบบต้นไม้

ใช้แสดงว่าข้อมูลแต่ละตัวถูกจัดกลุ่ม (Cluster) รวมกันอย่างไร ตามระดับความคล้ายกัน (Similarity) หรือระยะห่าง (Distance)



Hierarchical – Based Clustering

From Dataset → Clustering → Labels → Dendrogram
ตัวอย่าง Agglomerative

Algorithm

```
Z = linkage(X, method='complete', metric='euclidean')  
clusters = fcluster(Z, t=2, criterion='maxclust')
```

	Feature_1	Feature_2
0	1.190043	0.848595
1	-3.436033	8.082827
2	0.649228	10.549156
3	2.614217	2.601664
4	-2.977504	8.546012
5	2.823831	-0.851438
6	4.774935	-0.876327
7	-2.025273	5.187726
8	-3.448146	10.099406
9	7.571176	1.521617


Dataset

Hierarchical Clustering

- Single
- Complete
- Average
- Weighted
- Centroid
- Median
- Ward

	Cluster_1	Cluster_2	Cluster_ID	Sample_Count	Distance
0	1.0	4.0	10	2.0	0.651759
1	5.0	6.0	11	2.0	1.951263
2	8.0	10.0	12	3.0	2.016616
3	0.0	3.0	13	2.0	2.258655
4	11.0	13.0	14	4.0	4.094524
5	2.0	12.0	15	4.0	4.772016
6	7.0	15.0	16	5.0	5.991485
7	9.0	14.0	17	5.0	6.416527
8	16.0	17.0	18	10.0	13.964381

Results



Dendrogram

Hierarchical – Based Clustering

Hierarchical Clustering Results → Dendrogram

ตัวอย่าง Agglomerative

Dataset

	Feature_1	Feature_2
0	1.190043	0.848595
1	-3.436033	8.082827
2	0.649228	10.549156
3	2.614217	2.601664
4	-2.977504	8.546031
5	2.823831	-0.851439
6	4.774935	-0.876327
7	-2.025273	5.187726
8	-3.448146	10.099406
9	7.571176	1.521617

Mapping ของ
linkage matrix


Results

	Cluster_1	Cluster_2	Cluster_ID	Sample_Count	Distance
0	1	4	10	2.0	0.651759
1	5	6	11	2.0	1.951263
2	8	10	12	3.0	2.016616
3	0	3	13	2.0	2.258655
4	11	13	14	4.0	4.094524
5	2	12	15	4.0	4.772016
6	7	15	16	5.0	5.991485
7	9	14	17	5.0	6.416527
8	16	17	18	10.0	13.964381

Hierarchical – Based Clustering

Hierarchical Clustering Results → Dendrogram


	Cluster_1	Cluster_2	Cluster_ID	Sample_Count	Distance
0	1	4	10	2.0	0.651759
1	5	6	11	2.0	1.951263
2	8	10	12	3.0	2.016616
3	0	3	13	2.0	2.258655
4	11	13	14	4.0	4.094524
5	2	12	15	4.0	4.772016
6	7	15	16	5.0	5.991485
7	9	14	17	5.0	6.416527
8	16	17	18	10.0	13.964381



Hierarchical – Based Clustering

Hierarchical Clustering Results → Dendrogram


	Cluster_1	Cluster_2	Cluster_ID	Sample_Count	Distance
0	1	4	10	2.0	0.651759
1	5	6	11	2.0	1.951263
2	8	10	12	3.0	2.016616
3	0	3	13	2.0	2.258655
4	11	13	14	4.0	4.094524
5	2	12	15	4.0	4.772016
6	7	15	16	5.0	5.991485
7	9	14	17	5.0	6.416527
8	16	17	18	10.0	13.964381




Hierarchical – Based Clustering

Hierarchical Clustering Results → Dendrogram

	Cluster_1	Cluster_2	Cluster_ID	Sample_Count	Distance
0	1	4	10	2.0	0.651759
1	5	6	11	2.0	1.951263
2	8	10	12	3.0	2.016616
3	0	3	13	2.0	2.258655
4	11	13	14	4.0	4.094524
5	2	12	15	4.0	4.772016
6	7	15	16	5.0	5.991485
7	9	14	17	5.0	6.416527
8	16	17	18	10.0	13.964381



Density – Based Clustering



Density – Based Clustering

Density-Based Clustering การจัดกลุ่มข้อมูลแบบอาศัยความหนาแน่น

เป็นวิธีการจัดกลุ่มข้อมูลใน ที่สร้างกลุ่มจากบริเวณที่มีข้อมูลกระจุกตัวหนาแน่น และแยกข้อมูลที่อยู่ห่างหรือกระจายตัวออกจากกลุ่ม โดยไม่จำเป็นต้องกำหนดจำนวนกลุ่มล่วงหน้า

หลักการสำคัญ: การพิจารณาความหนาแน่นของข้อมูลในพื้นที่ หากบริเวณใดมีจำนวนข้อมูลอยู่ใกล้กันมากพอ จะถูกจัดให้อยู่ในกลุ่มเดียวกัน ในขณะที่ข้อมูลที่อยู่โดดเดี่ยวหรืออยู่ในพื้นที่ที่มีความหนาแน่นต่ำ มักถูกจัดเป็นข้อมูลผิดปกติ (Anomaly Noise หรือ Outlier)

เหมาะกับข้อมูล ที่มีรูปร่างกลุ่มซับซ้อน และสามารถตรวจจับข้อมูลผิดปกติได้ดี

ตัวอย่างอัลกอริทึม

- DBSCAN
- HDBSCAN

พื้นฐานที่จำเป็น

- ความหนาแน่นของข้อมูล (Data Density)
- การวัดระยะห่างของข้อมูล (Distance Measurement)
- การกำหนดค่า eps (Neighborhood Radius)
- การกำหนดค่า min_samples (Minimum Points)
- การเชื่อมโยงข้อมูลที่อยู่ใกล้กัน (Neighborhood Connectivity)
- การตรวจจับข้อมูลผิดปกติ (Noise / Outlier Detection)
- การปรับขนาดข้อมูล (Data Scaling)

Density – Based Clustering

From Dataset → Clustering → Labels, Membership Score

Results

Dataset

	Feature_1	Feature_2
0	0.694710	10.164915
1	2.941106	2.259729
2	8.430558	5.661477
3	0.862619	10.459019
4	-10.024079	-5.158392


Algorithm

Density Clustering

- DBSCAN
- HDBSCAN

	Feature_1	Feature_2	Cluster	Core
0	0.554732	0.770643	0	1
1	0.637765	0.527948	0	1
2	0.840668	0.632384	0	1
3	0.560939	0.779672	0	1
4	0.158539	0.300206	1	1

Cluster = -1
คือ Noise



DBSCAN Clustering


DBSCAN (Density-Based Spatial Clustering of Applications with Noise)

คืออัลกอริทึมการจัดกลุ่มข้อมูลที่ใช้ ความหนาแน่นของจุดข้อมูล ในการสร้างกลุ่ม โดยสามารถค้นหากลุ่มที่มีรูปร่างซับซ้อนได้ และสามารถแยกข้อมูลที่เป็น Noise หรือ Outlier ออกได้


หลักการทำงาน

DBSCAN จะพิจารณาจุดข้อมูลจาก

- ϵ (Epsilon) = ระยะห่างที่ถือว่าจุดอยู่ใกล้กัน
- MinPts = จำนวนจุดขั้นต่ำที่ต้องมีเพื่อสร้างกลุ่ม
- ถ้าบริเวณใดมีจำนวนจุด $\geq$ MinPts ภายในระยะ ϵ จะถูกจัดเป็น Cluster และจะขยายกลุ่มไปยังจุดใกล้เคียง ส่วนจุดที่ไม่อยู่ในกลุ่มใดจะถูกจัดเป็น Noise (-1)



DBSCAN Clustering



HDBSCAN Clustering

HDBSCAN


Hierarchical Density-Based Spatial Clustering of Applications with Noise

คืออัลกอริทึมจัดกลุ่มข้อมูลแบบ Density-based ที่พัฒนาต่อยอดจาก DBSCAN โดยสามารถจัดการข้อมูลที่มี ความหนาแน่นแตกต่างกันหลายระดับ ได้ดี และสร้างโครงสร้างกลุ่มแบบลำดับชั้น (Hierarchical)

หลักการทำงาน

- HDBSCAN จะสร้างลำดับชั้นของกลุ่มจากระดับความหนาแน่นหลายค่า
- เลือกกลุ่มที่มี ความเสถียร (Cluster Stability) สูงที่สุดเป็นผลลัพธ์ โดยใช้พารามิเตอร์หลักคือ minimum cluster size
- แยกข้อมูลที่เป็น Noise/Outlier ได้โดยอัตโนมัติ

HDBSCAN Clustering





SCHOOL OF
ENGINEERING
BANGKOK UNIVERSITY

School of Engineering
Artificial Intelligence Engineering and Data Science

Q & A