

Lecture 4

Anomaly Detection

AIE324 — Unsupervised Machine Learning

Dr. Suparat Yeamkuan

ดร. ศุภรัตน์ แยมครวญ

suparat.y@bu.ac.th

School of Engineering
Artificial Intelligence Engineering and Data Science

Outline

- What's an Anomaly? and Applications
- Anomaly Detection Methods/Approaches
 - Statistic - Based
 - Distance - Based
 - Density - Based
 - Reconstruction Error-Based
- Algorithms for Time Series Data
- Q&A

What is Anomaly Detection?

การตรวจจับความผิดปกติ (Anomaly Detection)



หรือที่เรียกว่า การตรวจจับค่าผิดปกติ (Outlier Detection) คือกระบวนการค้นหาข้อมูลที่มีลักษณะผิดปกติหรือแตกต่างจากข้อมูลส่วนใหญ่

การตรวจจับความผิดปกติเป็นเทคนิคที่ใช้ในการระบุรูปแบบข้อมูลที่ผิดปกติ ซึ่งไม่เป็นไปตามพฤติกรรมหรือรูปแบบที่คาดหวัง




Anomaly Detection Applications

- Financial Fraud
- Cybersecurity
- Video Surveillance
- Medical Image Analysis
- Defense and Internal Security
- Manufacturing and Industry



Anomaly Detection Methods/Approaches



Statistic – Based Anomaly Detection



Statistic - Based Anomaly Detection

Statistic-Based Anomaly Detection หรือ การตรวจจับความผิดปกติแบบวิธีสถิติ

เป็นวิธีการระบุข้อมูลหรือเหตุการณ์ที่พบได้น้อย หรือแตกต่าง โดยพิจารณาค่าทางสถิติ เมื่อเปรียบเทียบกับรูปแบบ หรือการกระจาย (Statistical Patterns or Distributions) ทางสถิติที่ถูกกำหนดไว้ของชุดข้อมูล

โดยข้อมูลผิดปกติ (Anomaly) มักมีค่าที่แตกต่างหรืออยู่ห่างจากค่าปกติ ซึ่งสามารถใช้ค่าทางสถิติเพื่อวัดระดับความแตกต่างได้

ตัวอย่างตรวจจับความผิดปกติแบบวิธีสถิติ


- Histogram/Distribution
- Z-Score
- IQR

พื้นฐานสถิติที่จำเป็น


- ค่าเฉลี่ย (Mean)
- ส่วนเบี่ยงเบนมาตรฐาน (Standard Deviation)
- ควอไทล์ (Quartile)
- ความน่าจะเป็น (Probability)

Statistic – Based: Histogram/Distribution


- วิธีตรวจสอบความผิดปกติแบบสถิติ จะใช้แบบการกระจายตัวของข้อมูลปกติ (Histogram/Distribution)
- ตรวจสอบข้อมูลที่มีโอกาสเกิดขึ้นต่ำกว่าปกติว่าเป็นข้อมูลผิดปกติ



(a) Gaussian—Histogram



(b) Beta—Histogram



(c) Gamma—Histogram

Statistic – Based : Histogram/Distribution

Scenario: Financial Fraud Detection

ธนาคารต้องการตรวจสอบธุรกรรมบัตรเครดิตที่ผิดปกติ

สมมติฐาน

- ลูกค้าปกติใช้จ่ายประมาณ 500 – 5000 บาท
- ธุรกรรมที่สูงผิดปกติอาจเป็น Fraud

ขั้นตอน

Transaction Data



Histogram / Distribution




Calculate Z-score



Threshold Detection



Fraud Transaction



Transaction_Amount	Z_score	Anomaly
9000.0	5.505278	Fraud
11000.0	7.220538	Fraud
13000.0	8.935798	Fraud
15000.0	10.651058	Fraud

Statistic – Based: Z-Score

Z-score normalization หรือที่เรียกว่า Z-score Normalization/ Standardization คือ เทคนิคการเตรียมข้อมูลเชิงสถิติ ที่ใช้สำหรับ ปรับสเกลข้อมูลตัวเลข ให้มีคุณสมบัติ

- ค่าเฉลี่ย (Mean) = 0
- ส่วนเบี่ยงเบนมาตรฐาน (Standard Deviation) = 1

Z-score ทำให้ข้อมูลอยู่ในรูปแบบมาตรฐาน โดยใช้สูตร

$$Z = \frac{X - \mu}{\sigma}$$

โดยที่

X = ค่าข้อมูลเดิม

μ = ค่าเฉลี่ยของข้อมูล


σ = ส่วนเบี่ยงเบนมาตรฐาน

$Z = 0$ → อยู่ตรงค่าเฉลี่ย

$Z > 0$ → ค่าสูงกว่าค่าเฉลี่ย

$Z < 0$ → ค่าต่ำกว่าค่าเฉลี่ย

Detecting Outliers with z-Scores



Statistic – Based: Z-Score

Scenario: Financial Fraud Detection

โรงงานต้องการตรวจการสั่นที่ผิดปกติของเครื่องจักร

กำหนดการตรวจจับ

- Threshold = 3
- Z-Score > Threshold

สมมติฐาน




→ Normal State

ค่าการสั่นอยู่ประมาณ 4 – 6 mm/s
แสดงว่าเครื่องจักรทำงานปกติ


→ Abnormal State

ค่าที่สูงผิดปกติ ประมาณ 8 – 10 mm/s
อาจเกิดจาก

- Bearing damage
- Rotor imbalance
- Shaft misalignment
- Mechanical looseness




Statistic – Based: Z-Score



กำหนดการตรวจจับ

- Threshold = 3
- Z-Score > Threshold


Statistic – Based: Z-Score



$\pm 2\sigma$

กำหนดการตรวจจับ

- Threshold = 2
- Z-Score > Threshold




$\pm 1\sigma$

กำหนดการตรวจจับ

- Threshold = 1
- Z-Score > Threshold

Statistic – Based: Z-Score (2 Dimensional)



Statistic – Based: IQR

IQR (Interquartile Range) คือ วิธีตรวจสอบข้อมูลผิดปกติโดยใช้การกระจายตัวของข้อมูลจาก Quartiles

IQR วัดช่วงของข้อมูลตรงกลาง

$$IQR = Q3 - Q1$$

โดยที่

Q1 (First Quartile). → 25% ของข้อมูล

Q2 (Median). → 50% ของข้อมูล


Q3 (Third Quartile) → 75% ของข้อมูล

หลักการตรวจสอบใช้การกำหนดขอบเขตข้อมูลปกติ

$$Lower = Q1 - 1.5 \times IQR$$


$$Upper = Q3 + 1.5 \times IQR$$

- IQR เหมาะกับข้อมูลที่มีการกระจายแบบเอียง (Skewed) หรือแบบ Long-tailed
- IQR คำนวณจาก ควอไทล์ (Quartiles) ไม่ได้ใช้ค่าเฉลี่ยและส่วนเบี่ยงเบนมาตรฐาน




Statistic – Based: IQR

ตัวอย่างการกระจายแบบเอียง (Skewed) และแบบ Long-tailed



Distance – Based Anomaly Detection



Distance - Based Anomaly Detection

Distance-Based Anomaly Detection หรือ การตรวจจับความผิดปกติแบบวิธีการวัดระยะห่างข้อมูล

เป็นวิธีตรวจจับข้อมูลผิดปกติ โดยพิจารณาความ เหมือนหรือแตกต่างของข้อมูลจากระยะห่าง (Distance) ระหว่างจุดข้อมูล

อัลกอริทึมจะคำนวณ **ระยะห่างระหว่างข้อมูลแต่ละจุด** โดยตั้งสมมติฐานว่า

- ข้อมูลปกติ → มักอยู่ในบริเวณที่มีข้อมูลหนาแน่น
- ข้อมูลผิดปกติ (Anomaly) → มักอยู่ในบริเวณที่มีข้อมูลกระจายหรือเบาบาง


ตัวอย่างตรวจจับความผิดปกติแบบวิธีวัดระยะทาง

- k-Nearest Neighbors (k-NN)
- Centroid-Based

พื้นฐาน Distance ที่จำเป็น


- Euclidean Distance
- Manhattan Distance
- Mahalanobis Distance
- Cosine Similarity

Basic of Distance - Based Anomaly Detection




(a) Euclidean

$$d = \sqrt{\sum_{i=1}^n (x_i - y_i)^2}$$




(b) Manhattan

$$d = \sum |x_i - y_i|$$



(c) Cosine

$$\text{Similarity} = \frac{A \cdot B}{||A|| ||B||}$$



(d) Mahalanobis

$$d = \sqrt{(x - \mu)^T S^{-1} (x - \mu)}$$


k-Nearest Neighbors (k-NN) Anomaly Detection

วิธีตรวจจับข้อมูลผิดปกติโดยใช้แนวทาง k-NN ในการตรวจจับข้อมูลผิดปกติ อาศัยสมมติฐานพื้นฐาน

“สิ่งที่มีลักษณะคล้ายกัน มักจะอยู่ใกล้กัน”

- ข้อมูลปกติ (Normal data) มักอยู่ใกล้กับข้อมูลอื่น
- ข้อมูลผิดปกติ (Anomaly) มักอยู่โดดเดี่ยว หรืออยู่ไกลจากกลุ่มข้อมูล

อัลกอริทึมจะระบุข้อมูลที่เป็นค่าผิดปกติ (outliers) โดยตรวจสอบความผิดปกติของ การกระจายตัวของระยะทางระหว่าง Point ตัวเอง กับ Point เพื่อนบ้าน (Nearest Neighbors) ที่ใกล้ที่สุดจำนวน k จุด



k-Nearest Neighbors (k-NN) Anomaly Detection


ขั้นตอน

1. เตรียมข้อมูล และเลือกค่า k
↓
2. คำนวณ Distance
↓
3. หา k Nearest Neighbors
↓
4. คำนวณ Anomaly Score
↓
5. กำหนด Threshold
↓
6. แยก Normal / Anomaly
(Percentile Calculation & Threshold)

	Feature 1	Feature 2
0	1.0	1.0
1	0.5	2.0
2	2.0	1.0
3	2.0	2.0
4	3.0	5.0
5	5.5	3.0
6	8.0	8.0

กำหนด

- $k = 3$
- Threshold = 50%




1. เตรียมข้อมูล และเลือกค่า k

k-Nearest Neighbors (k-NN) Anomaly Detection

คำนวณระยะทางจาก P1 ไปยังทุก Data Points → เลือก 3 Data Points ใกล้สุด → Average

Point
P1



Distance from P1 to others:

P1 → P1 = 0.000

P1 → P2 = 1.118

P1 → P3 = 1.000

P1 → P4 = 1.414

P1 → P5 = 4.472

P1 → P6 = 4.924

P1 → P7 = 9.899

P1 → P8 = 10.630

2. คำนวณ
Distance

3-Nearest Neighbors of P1:

P3 = 1.000

P2 = 1.118

P4 = 1.414


3. หา k Nearest
Neighbors

P1 Average Distance (k=3) = 1.177

4. คำนวณ
Anomaly
Score

k-Nearest Neighbors (k-NN) Anomaly Detection

คำนวณระยะทางจาก P2 ไปยังทุก Data Points → เลือก 3 Data Points ใกล้สุด → Average



Distance from P2 to others:

P2 → P1 = 1.118

P2 → P2 = 0.000

P2 → P3 = 1.803

P2 → P4 = 1.500

P2 → P5 = 3.905

P2 → P6 = 5.099

P2 → P7 = 9.605

P2 → P8 = 10.404

2. คำนวณ
Distance

3-Nearest Neighbors of P2:

P1 = 1.118

P4 = 1.500

P3 = 1.803

3. เลือก k Nearest
Neighbors

P2 Average Distance (k=3) = 1.474

4. คำนวณ
Anomaly
Score

k-Nearest Neighbors (k-NN) Anomaly Detection

Point
P1-P8

กำหนด Threshold → แยก Normal / Anomaly

	Point	k-NN	Distances	Average Distance
0	P1	[P3, P2, P4]	[1.0, 1.118, 1.414]	1.177
1	P2	[P1, P4, P3]	[1.118, 1.5, 1.803]	1.474
2	P3	[P1, P4, P2]	[1.0, 1.0, 1.803]	1.268
3	P4	[P3, P1, P2]	[1.0, 1.414, 1.5]	1.305
4	P5	[P4, P6, P2]	[3.162, 3.202, 3.905]	3.423
5	P6	[P5, P4, P3]	[3.202, 3.64, 4.031]	3.624
6	P7	[P8, P6, P5]	[1.0, 5.59, 5.831]	4.140
7	P8	[P7, P6, P5]	[1.0, 6.103, 6.708]	4.604



Threshold = 50%



Percentile Calculation
& Threshold

k-Nearest Neighbors (k-NN) Anomaly Detection

Percentile Calculation & Threshold

	Point	k-NN	Distances	Average Distance
0	P1	[P3, P2, P4]	[1.0, 1.118, 1.414]	1.177
1	P2	[P1, P4, P3]	[1.118, 1.5, 1.803]	1.474
2	P3	[P1, P4, P2]	[1.0, 1.0, 1.803]	1.268
3	P4	[P3, P1, P2]	[1.0, 1.414, 1.5]	1.305
4	P5	[P4, P6, P2]	[3.162, 3.202, 3.905]	3.423
5	P6	[P5, P4, P3]	[3.202, 3.64, 4.031]	3.624
6	P7	[P8, P6, P5]	[1.0, 5.59, 5.831]	4.140
7	P8	[P7, P6, P5]	[1.0, 6.103, 6.708]	4.604

เรียงลำดับข้อมูล จากน้อยไปมาก

↓
คำนวณหา index ของ Percentile
สูตรพื้นฐาน

$$i = \frac{p}{100}(N - 1)$$

โดย
p = percentile และ N = จำนวนข้อมูล

จากกำหนด Threshold = 50%

$$i = \frac{50}{100}(8 - 1) = 3.5$$

คู่ตัวเลขค่าระหว่าง $i = 3.5 \rightarrow i = 3$ คือ P2 และ P5

ทำ interpolation 0.5 คือกศนิยม จาก 3.5

$$value = P2 + 0.5(P5 - P2)$$

$$value = 1.474 + 0.5(3.423 - 1.474)$$

$$threshold \approx 2.4485$$

	Point	Avg kNN Distance
0	P1	1.177
1	P3	1.268
2	P4	1.305
3	P2	1.474
4	P5	3.423
5	P6	3.624
6	P7	4.140
7	P8	4.604

k-Nearest Neighbors (k-NN) Anomaly Detection


P1 - P8 : Threshold = 2.4485

ทำ interpolation

$threshold \approx 2.4485$

Data Points
ที่มีค่ามากกว่า
2.4485

	Point	Feature1	Feature2	Distance	Anomaly
0	P1	1.0	1.18	1.177	False
1	P2	0.5	2.0	1.474	False
2	P3	2.0	1.0	1.268	False
3	P4	2.0	2.0	1.305	False
4	P5	3.0	5.0	3.423	True
5	P6	5.5	3.0	3.624	True
6	P7	8.0	8.0	4.140	True
7	P8	9.0	8.0	4.604	True




Centroid-Based Anomaly Detection

วิธีตรวจจับข้อมูลผิดปกติโดยใช้แนวทาง จุดศูนย์กลางของกลุ่มข้อมูล (Centroids) ในการตรวจจับข้อมูลผิดปกติ อาศัยสมมติฐานพื้นฐาน

- ข้อมูลปกติ มักจะอยู่รวมกันเป็นกลุ่มก้อนหนาแน่นใกล้กับ จุดศูนย์กลาง (Centroids)
- ข้อมูลผิดปกติ (Anomalies/Outliers) จะมีลักษณะที่แตกต่างออกไป ซึ่งส่งผลให้ตรวจจับได้ใน ระยะทางที่ห่างไกล (High Distance)

ข้อมูลที่เป็น Anomaly จะอยู่ห่างจากจุดศูนย์กลางของกลุ่มที่มันถูกจัดเข้าไ้มากเกินไป

อัลกอริทึมจะระบุข้อมูลที่เป็นค่าผิดปกติ (outliers) โดยข้อมูลจะถูกพิจารณาเป็น outlier หากระยะทางของข้อมูลมีค่ามากกว่าค่า threshold ที่กำหนดจาก percentile ของระยะทางทั้งหมด



ตัวอย่าง K-Mean Centroid-Based Anomaly Detection

Centroid-Based Anomaly Detection


ขั้นตอน

1. เตรียมข้อมูล
- ↓
2. คำนวณ Centroid (Mean)
- ↓
3. คำนวณ Distances
- ↓
5. กำหนด Threshold
- ↓
6. แยก Normal / Anomaly (Percentile Calculation & Threshold)

	Label	Feature1	Feature2
0	P1	1.0	1.0
1	P2	0.5	2.0
2	P3	2.0	1.0
3	P4	2.0	2.0
4	P5	3.0	5.0
5	P6	5.5	3.0
6	P7	8.0	8.0
7	P8	9.0	8.0


กำหนด

- Threshold = 30 % (Percentile)



Centroid-Based Anomaly Detection

คำนวณ Centroid (Mean) → คำนวณระยะทางไปยังทุก Data Points



2. คำนวณ
Centroid

Centroid: [3.875 3.75]
Centroid-x1: 3.875
Centroid-x2: 3.75

3. คำนวณ
Distance

	Label	Feature1	Feature2	Distance
0	P1	1.0	1.0	3.978458
1	P2	0.5	2.0	3.801727
2	P3	2.0	1.0	3.328382
3	P4	2.0	2.0	2.564786
4	P5	3.0	5.0	1.525819
5	P6	5.5	3.0	1.789728
6	P7	8.0	8.0	5.922679
7	P8	9.0	8.0	6.657937

Centroid-Based Anomaly Detection

Percentile Calculation & Threshold

	Label	Feature1	Feature2	Distance
0	P1	1.0	1.0	3.978458
1	P2	0.5	2.0	3.801727
2	P3	2.0	1.0	3.328382
3	P4	2.0	2.0	2.564786
4	P5	3.0	5.0	1.525819
5	P6	5.5	3.0	1.789728
6	P7	8.0	8.0	5.922679
7	P8	9.0	8.0	6.657937

เรียงลำดับข้อมูล จากน้อยไปมาก



คำนวณหา index ของ Percentile
สูตรพื้นฐาน

$$i = \frac{p}{100}(N - 1)$$

โดย

p = percentile และ N = จำนวนข้อมูล

จากกำหนด Threshold = 30%

$$i = \frac{30}{100}(8 - 1) = 2.1$$

คู่ตัวเลขค่าระหว่าง $i = 2.1 \rightarrow i = 2$ คือ P4 และ P3

ทำ interpolation 0.1 คือทศนิยมจาก 2.1


$$\begin{aligned} value &= P4 + 0.1(P3 - P4) \\ value &= 2.564786 + 0.1(3.328382 - 2.564786) \end{aligned}$$

$$threshold \approx 2.6411$$

	Label	Distance
0	P5	1.525819
1	P6	1.789728
2	P4	2.564786
3	P3	3.328382
4	P2	3.801727
5	P1	3.978458
6	P7	5.922679
7	P8	6.657937

Centroid-Based Anomaly Detection

กำหนด Threshold → คำนวณ Percentile → แยก Normal / Anomaly



Percentile Calculation
& Threshold

Centroid: [3.875, 3.75]
Centroid-x1: 3.875
Centroid-x2: 3.75

Percentile Threshold (30%): 2.641

Result Table


	Feature1	Feature2	Label	Distance	Outlier
0	1.0	1.0	P1	3.978458	True
1	0.5	2.0	P2	3.801727	True
2	2.0	2.0	P3	3.328382	True
3	4.0	2.0	P4	2.564786	False
4	3.0	5.0	P5	1.525819	False
5	5.5	3.0	P6	1.789728	False
6	8.0	8.0	P7	5.922679	True
7	9.0	8.0	P8	6.657937	True

Data Points
มีค่ามากกว่า 2.641

Anomaly Detection

Density - Based

Reconstruction Error - Based



Density - Based Anomaly Detection

Density -Based Anomaly Detection หรือ การตรวจจับความผิดปกติแบบวิธีกลุ่มความหนาแน่นของข้อมูล

เป็นวิธีตรวจจับข้อมูลผิดปกติ โดยพิจารณาความ เหมือนหรือแตกต่างของข้อมูล จากความหนาแน่นของข้อมูล

อัลกอริทึมพิจารณาจาก **ความหนาแน่นของข้อมูลในพื้นที่คุณลักษณะ (Feature Space)** โดยตั้งสมมติฐานว่า

- ข้อมูลปกติ → มักรวมตัวกันเป็นกลุ่มที่มีความหนาแน่นสูง
- ข้อมูลผิดปกติ (Anomaly) → มักพบได้น้อย มีความหนาแน่นต่ำ หรือกระจายตัว


ตัวอย่างตรวจจับความผิดปกติแบบวิธีกลุ่มความหนาแน่นของข้อมูล

- DBSCAN
- LOF (Local Outlier Factor)

พื้นฐาน Density ที่จำเป็น


- Density และ Local Density
- Neighborhood
- Distance Metric

Density - Based Anomaly Detection




An Example Illustrating the Density-Based DBSCAN Clustering Method Applied to SMLM Data
A Review of Super-Resolution Single-Molecule Localization Microscopy Cluster Analysis and Quantification Methods

Density - Based Anomaly Detection



GMM Likelihood-Based



Local Outlier Factor (LOF)

Reconstruction Error - Based Anomaly Detection

Reconstruction Error - Based Anomaly Detection หรือ การตรวจจับความผิดปกติแบบวิธีค่าความคลาดเคลื่อนจากการสร้างข้อมูลใหม่

เป็นการตรวจจับข้อมูลผิดปกติ โดยวัดความแตกต่างระหว่างข้อมูลจริงกับข้อมูลที่โมเดลสร้างกลับขึ้นมา **หลังจากการลดมิติ (Reconstruction)** หากค่าความคลาดเคลื่อนสูง (Error) แสดงว่าข้อมูลนั้นอาจเป็น Anomaly

โดยพิจารณาจาก ค่าความคลาดเคลื่อนของข้อมูลที่โมเดลสร้างกลับ (Reconstruction Error) บน สมมติฐาน

- ข้อมูลปกติ → มีค่าความคลาดเคลื่อน (Error) ต่ำ
- ข้อมูลผิดปกติ (Anomaly) → มีค่าความคลาดเคลื่อน (Error) สูง



ตัวอย่างตรวจจับความผิดปกติแบบวิธีกลุ่มความหนาแน่นของข้อมูล

- Principal Component Analysis (PCA)
- Singular Value Decomposition (SVD)
- Autoencoder

พื้นฐาน Reconstruction Error ที่จำเป็น


- Dimensional Reduction
- Reconstruction Method
- Reconstruction Error

Reconstruction Error - Based Anomaly Detection



Principal Component Analysis (PCA)

Reconstruction Error - Based Anomaly Detection



Singular Value Decomposition (SVD)

Anomaly Detection Algorithms for Time-Series Data



Anomaly Detection Algorithms for Time-Series Data

Anomaly Detection for Time-Series Data หรือ การตรวจจับความผิดปกติสำหรับข้อมูลเชิงเวลา/อนุกรมเวลา

เป็นการตรวจจับจุดข้อมูลหรือช่วงของข้อมูล (Point or Sequence Data) ที่มีความแตกต่างจากรูปแบบของข้อมูลตามลำดับเวลา

โดยพิจารณาจากค่าสถิติ รูปแบบ หรือพฤติกรรมของข้อมูลตามลำดับเวลาก่อนหน้า หรือช่วงข้อมูล โดยตั้งอยู่บนสมมติฐาน ตามตัวชี้วัดความผิดปกติ (Anomaly Metrics/Score) ว่า

- ข้อมูลปกติ → ค่าตัวชี้วัด ต่ำ หรืออยู่ในช่วงที่คาดการณ์ได้
- ข้อมูลผิดปกติ (Anomaly) → ค่าตัวชี้วัด สูง หรือเบี่ยงเบนจากรูปแบบที่คาดการณ์ไว้


ประเภทของการตรวจจับความผิดปกติสำหรับข้อมูลเชิงเวลา

- Point Anomaly (ความผิดปกติแบบจุดเดียว)
- Contextual Anomaly (ความผิดปกติตามบริบท)
- Collective Anomaly (ความผิดปกติแบบลำดับข้อมูล)

พื้นฐาน Time-Series ที่จำเป็น


- Time-Series Data Definition
- Anomaly Detection Algorithm

Anomaly Detection Algorithms for Time-Series Data



Anomaly Detection Algorithms for Time-Series Data

Example: ការប្រើ Z-Score ប្រាំ IQR រក្សា Time-Series Data





SCHOOL OF
ENGINEERING
BANGKOK UNIVERSITY

School of Engineering
Artificial Intelligence Engineering and Data Science

Q & A